

Precificação dinâmica de estúdios por temporada com algoritmos "multi-armed bandits"

Kleber Ricardo de Abreu^{1*}; Larissa Simões²

MBA em Data Science e Analytics. Universidade de São Paulo — Escola Superior de Agricultura Luiz de Queiroz (USP/ESALQ). Piracicaba, SP, Brasil

¹ *Autor correspondente: kleber.rabreu@gmail.com

² Orientadora. MBA em Data Science e Analytics. USP/ESALQ. Piracicaba, SP, Brasil

Precificação dinâmica de estúdios por temporada com algoritmos "multi-armed bandits"

Commented [LGI]: Confere se o template é esse mesmo, 2025

Resumo

Plataformas digitais de hospedagem transformaram o mercado de aluguel por temporada na última década, e a precificação passou a determinar, mais do que antes, o desempenho econômico dos imóveis. Este trabalho investigou como algoritmos da classe "Multi-Armed Bandits" [MAB] podem otimizar essa decisão de preço. Compararam-se três estratégias: ϵ -Greedy, "Upper Confidence Bound" [UCB] e "Thompson Sampling" [TS]. A base analítica reuniu dados públicos de 571 estúdios no Rio de Janeiro entre junho de 2024 e março de 2025, totalizando 2.284 observações em painel balanceado. A qualidade percebida dos imóveis foi sintetizada por Análise de Componentes Principais [PCA], e a demanda foi modelada por regressão linear ordinária [OLS] com sete variáveis significativas. O modelo explicou 10% da variação na ocupação — limite que reflete a complexidade inerente ao mercado de hospitalidade, onde preferências subjetivas pesam tanto quanto atributos mensuráveis. As simulações contemplaram 1.000 rodadas e 50 repetições estocásticas em dois cenários. No cenário estacionário, o UCB maximizou a receita acumulada, seguido por ϵ -Greedy e TS. No cenário dinâmico multi-estação, o UCB manteve a receita absoluta mais alta, porém o TS apresentou queda relativa menor entre cenários, revelando maior capacidade de ajuste à volatilidade sazonal. Em mercados que oscilam, a adaptabilidade bayesiana do TS compensou o custo moderado de exploração ao longo de horizontes suficientemente longos.

Palavras-chave: hospedagem de curta duração; aprendizado por reforço; otimização de receita; sazonalidade turística; decisão sequencial sob incerteza.

Dynamic pricing of short-term rental studios with multi-armed bandit algorithms

Abstract

Digital accommodation platforms reshaped the short-term rental market over the past decade, and pricing became a sharper determinant of property performance than before. This study examined how Multi-Armed Bandit (MAB) algorithms can refine that pricing decision, comparing three strategies: ϵ -Greedy, Upper Confidence Bound (UCB), and Thompson Sampling (TS). The analytical base drew on public data for 571 studio apartments in Rio de Janeiro between June 2024 and March 2025, totaling 2,284 observations in a balanced panel. Perceived quality was condensed through Principal Component Analysis (PCA), and quarterly occupancy was modeled by Ordinary Least Squares (OLS) regression with seven significant predictors. The model explained 10% of the variation in occupancy — a ceiling that reflects the complexity of the hospitality market, where subjective preferences weigh as heavily as measurable attributes. Simulations ran over 1,000 rounds with 50 stochastic replications in two scenarios. In the stationary setting, UCB maximized cumulative revenue, followed by ϵ -Greedy and TS. Under a dynamic multi-season regime, UCB still held the highest absolute revenue, but TS showed a smaller relative decline between scenarios, signaling greater adaptability to seasonal volatility. Across sufficiently long horizons in oscillating markets, the Bayesian flexibility of Thompson Sampling offset its moderate exploration cost.

Keywords: short-term rental; reinforcement learning; revenue optimization; tourism seasonality; sequential decision-making under uncertainty.

Introdução

O mercado de aluguel por temporada passou por transformação expressiva na última década. A consolidação de plataformas digitais de hospedagem ampliou o acesso de anfitriões individuais a mercados competitivos e elevou as expectativas dos hóspedes quanto à relação custo-benefício. Abrate et al. (2022) documentaram que anfitriões profissionais reajustam preços com maior frequência e precisão, e que essa sofisticação na precificação resulta em ocupação e receita superiores. A implicação é direta: a fixação estática de preços tornou-se insuficiente num mercado em que a comparação entre imóveis é imediata.

A precificação dinâmica emergiu como alternativa a esse modelo estático. Neubert (2022), em revisão sistemática, identificou ganhos de receita consistentes em diferentes setores com a adoção de métodos adaptativos, ressaltando que a aceitação pelos consumidores depende da percepção de justiça. Talón-Ballesteros et al. (2022) descreveram a evolução rumo ao "open pricing" — modelo em que cada unidade tem preço determinado de forma independente e contínua —, sugerindo que o futuro da precificação em hospitalidade passa pela individualização e automação. A adoção de ferramentas algorítmicas, contudo, permaneceu limitada. Foroughifar e Mehta (2024) identificaram que a desconfiança no algoritmo e a percepção de perda de controle constituem os principais obstáculos, reforçando a relevância de abordagens metodologicamente transparentes.

A definição do preço ótimo em ambiente incerto envolve dilema contínuo entre explorar novas faixas de preço e explorar as já conhecidas por bom desempenho. A formulação rigorosa desse "trade-off" remete à classe de algoritmos "Multi-Armed Bandits" [MAB]. Auer et al. (2002) demonstraram que o "Upper Confidence Bound" [UCB] oferece garantias de "regret" logarítmico — o custo da exploração diminui de forma controlada sem exigir conhecimento prévio das distribuições de retorno. Russo et al. (2018) formalizaram as propriedades do "Thompson Sampling" [TS], evidenciando convergência teórica e desempenho empírico particularmente favorável em cenários não estacionários.

O presente estudo investigou a aplicação desses algoritmos à precificação dinâmica de estúdios em plataforma digital de hospedagem, utilizando dados do Rio de Janeiro — 571 estúdios com histórico de preços e ocupação entre junho de 2024 e março de 2025 — como ambiente de simulação. O objetivo central foi comparar ϵ -Greedy, UCB e TS na maximização de receita, em cenários estacionário e multi-estação. A investigação articulou-se em torno de cinco questões: quais atributos do imóvel influenciam mais fortemente o sucesso dos algoritmos; como a sazonalidade altera o panorama competitivo entre as estratégias; qual algoritmo domina em cada tipo de cenário; quão estáveis e adaptáveis são os algoritmos frente a mudanças de mercado; e quais "trade-offs" cada estratégia encarna entre exploração e exploração.

Metodologia

Commented [LG2]: Confere no manual se a maneira de apresentar siglas é essa mesmo..

Commented [KR2R2]: Confirmei, é dessa forma mesmo. Obg.

Commented [LG3]: Itálico, não aspas

Commented [KR3R2]: Oi Larissa, eu confirmei no manual e palavras em outro idioma devem ficar com aspas duplas, apenas palavras em Latin devem ser escritas em itálico.

O estudo desenvolveu-se em três etapas sequenciais: preparação dos dados, modelagem da demanda e simulação dos algoritmos de precificação. Na primeira, partiu-se de dados públicos de uma plataforma digital de hospedagem, submetidos a coleta, tratamento e engenharia de variáveis; indicadores de qualidade percebida foram consolidados por Análise de Componentes Principais [PCA].

A segunda etapa modelou a ocupação trimestral por regressão linear ordinária [OLS], relacionando-a ao preço da diária e a variáveis de controle. Esse modelo serviu de função de demanda para a terceira etapa, um ambiente de simulação no qual foram testados três algoritmos "Multi-Armed Bandits" [MAB] — ϵ -Greedy, "Upper Confidence Bound" [UCB] e "Thompson Sampling" [TS] — em cenário estacionário e em cenário dinâmico multi-estação. O ajuste da função de demanda foi avaliado por coeficiente de determinação e validação cruzada agrupada; o desempenho dos algoritmos MAB, pela receita acumulada, pela frequência de braços selecionados e pela queda relativa de receita entre cenários.

Fonte de dados e recorte amostral

Os dados utilizados neste trabalho foram obtidos do Inside Airbnb [Inside Airbnb] (2024), repositório público e independente que compila informações sobre anúncios e calendários de disponibilidade da plataforma Airbnb em diversas cidades. O acesso é livre e por download direto, sem cadastro, e os arquivos destinam-se a pesquisa e análise acadêmica. Para o Rio de Janeiro, coletaram-se quatro snapshots trimestrais — junho, setembro e dezembro de 2024 e março de 2025 —, totalizando aproximadamente 140 mil registros brutos de anúncios e mais de 55 milhões de registros de calendário. A escolha dessas datas decorreu de uma restrição da própria plataforma: o Inside Airbnb mantém acesso gratuito apenas aos snapshots dos últimos 12 meses, em periodicidade trimestral. As quatro extrações correspondem, portanto, à totalidade dos dados públicos disponíveis no momento da coleta.

A escolha do Rio de Janeiro foi intencional: a concentração expressiva de estúdios em regiões turísticas de alto padrão e a conhecida sazonalidade da demanda amplificam os desafios de precificação enfrentados pelos anfitriões (Ye et al., 2018). Embora o projeto inicial mencionasse "grandes centros metropolitanos", optou-se por restringir o escopo a uma única cidade. Essa decisão favoreceu análise mais aprofundada e dados mais homogêneos, em detrimento de cobertura geográfica ampla, dada a limitação de cidades brasileiras disponíveis para "download" na plataforma.

Priorizou-se homogeneidade estrutural para reduzir heterogeneidade e aumentar comparabilidade dos resultados. Os critérios de filtragem constam da Tabela 1 abaixo.

Tabela 1. Critérios de filtragem da amostra e justificativas

Critério	Parâmetro	Justificativa
Tipo de propriedade	"Rental unit", "loft", "condo"	Apartamentos completos, excluindo quartos privados ou compartilhados
Tipo de quarto	"Entire home/apt"	Eliminar quartos compartilhados
Capacidade	≤ 3 pessoas	Perfil de estúdio
Quartos	≤ 1	Perfil de estúdio
Máximo de noites	≤ 90	Excluir imóveis residenciais de longo prazo
Status do anfitrião	"Superhost"	Garantir qualidade mínima e consistência da amostra
Camas	≤ 3	Consistência com capacidade máxima

Fonte: Dados originais da pesquisa

O filtro por "superhost" merece nota específica. Ao restringir-se a anfitriões com esse status, assegurou-se um patamar mínimo de qualidade de serviço e regularidade de atividade, reduzindo a variabilidade decorrente de anfitriões esporádicos. Essa escolha implica que os resultados refletem um segmento específico do mercado — anfitriões experientes e bem avaliados —, não sendo diretamente generalizáveis ao universo total de anfitriões.

O critério de inclusão exigiu que cada imóvel estivesse presente nos quatro snapshots, filtragem que eliminou entradas intermitentes e viabilizou a comparação temporal direta. Como resultante foram selecionados 571 imóveis e 2.284 observações. A variável-alvo, total de dias ocupados em janela trimestral prospectiva ($m+1$, $m+2$ e $m+3$), foi calculada a partir dos registros de disponibilidade da plataforma. Dias classificados como indisponíveis foram interpretados como ocupados, e a taxa de ocupação resultou da razão entre o número de dias ocupados e 91, a extensão máxima da janela trimestral.

Variáveis utilizadas

As variáveis foram organizadas em quatro grupos conceituais. O primeiro reuniu características estruturais: tipo de propriedade, capacidade de acomodação, número de quartos e camas, número mínimo de noites e quantidade de anúncios do anfitrião. O segundo compreendeu dimensões de preço: a diária em reais e o desconto relativo em relação à mediana do bairro.

Indicadores de qualidade percebida formaram o terceiro grupo — sete tipos de notas de avaliação (nota geral, precisão, limpeza, "check-in", comunicação, localização e custo-benefício), número de avaliações e taxa de avaliações por mês. O quarto grupo incluiu variáveis de contexto: bairro do imóvel, ocupação média do bairro por período e estação do ano. A variável dependente foi a taxa de ocupação trimestral.

Tratamento de dados e engenharia de variáveis

Começou-se padronizando tipos de dados e convertendo variáveis monetárias. Para valores faltantes, aplicou-se imputação por mediana em 17 registros sem notas de avaliação (0,74%) e dois registros sem preço (0,09%).

Valores extremos foram tratados por winsorização nos percentis 1 e 99. Essa técnica substitui observações atípicas pelos respectivos limites, preservando o tamanho amostral e reduzindo a influência de "outliers" sobre os estimadores sem eliminá-los (Wilcox, 2021). Aplicou-se às variáveis preço, número de avaliações, avaliações por mês e número de anúncios do anfitrião, afetando 47 registros de preço (2,1%).

Transformações logarítmicas via $\log(1+x)$ foram aplicadas a variáveis com distribuição assimétrica à direita, aproximando-as de distribuições mais simétricas e reduzindo influência de valores extremos, a comparação das distribuições antes e depois das transformações estão na Figura 1.




Figura 1. Histogramas comparativos das distribuições antes e depois do tratamento para preço (A), número de avaliações (B) e avaliações por mês (C)

Fonte: Resultados originais da pesquisa

Commented [LG4]: Cada gráfico tem que ter uma identificação. Pode ser a b c, mas aí cada um com uma letra, indo até f, ou a1/a2, etc

Os tipos de notas foram reescalados para a faixa 0 a 100. Zeros foram convertidos em valores ausentes — interpretados como falta de avaliação — e aplicou-se um piso de 40 pontos para eliminar valores espúrios. Os dados faltantes resultantes foram imputados pela mediana.

A engenharia de atributos derivou variáveis de contexto competitivo. A variável `discount_vs_median` capturou a diferença proporcional entre o preço do imóvel e a mediana do bairro. A variável `bairro_mean_ocup` representou a ocupação média do bairro por período, funcionando como "proxy" de atratividade geográfica. A sazonalidade foi capturada em quatro categorias: inverno (junho a agosto), primavera (setembro a novembro), verão (dezembro a fevereiro) e outono (março a maio). Os 32 bairros originais foram agrupados em seis categorias — os cinco com maior representação na amostra (Copacabana, Ipanema, Leblon, Centro e Jacarepaguá) mais uma categoria residual.

Consolidação de indicadores de qualidade via PCA

Aplicou-se Análise de Componentes Principais [PCA] para reduzir dimensionalidade e mitigar multicolinearidade entre os tipos de notas de avaliação. A PCA transforma um conjunto de variáveis possivelmente correlacionadas em um número menor de variáveis não correlacionadas — componentes principais — que capturam progressivamente a máxima variância dos dados originais (Jolliffe e Cadima, 2016). Quando há redundância entre variáveis explicativas, essa técnica consolida-as em indicadores sintéticos sem perda substancial de informação.

A análise incidiu sobre seis indicadores de qualidade percebida: nota geral, precisão, limpeza, "check-in", comunicação e custo-benefício. Excluiu-se a nota de avaliação de localização por representar atributo geográfico fixo, conceitualmente distinto dos demais indicadores de experiência. Avaliou-se a viabilidade da fatoração pelo índice Kaiser-Meyer-Olkin [KMO] e pelo teste de esfericidade de Bartlett. O componente principal retido, denominado `quality_score`, foi incorporado como variável de controle na etapa subsequente.

Seleção de variáveis para a função de demanda

A seleção das variáveis explicativas baseou-se em correlação de Spearman com a variável-alvo, avaliação de multicolinearidade e critérios conceituais. O coeficiente de Spearman, por ser não paramétrico, mostra-se robusto a não linearidades e distribuições assimétricas (Hollander et al., 2013).

Variáveis com elevada correlação entre si foram avaliadas quanto à redundância. Aquelas que não atingiram significância estatística ao nível de 5% no modelo multivariado foram eliminadas.

Modelagem da função de demanda

Estimou-se a função de demanda por dois modelos lineares complementares. O primeiro, regressão linear ordinária [OLS], modela a variável dependente como combinação linear dos preditores, estimando coeficientes pelo método dos mínimos quadrados (Wooldridge, 2020). O segundo, modelo linear misto [MixedLM] com intercepto aleatório por imóvel, captura heterogeneidade não observada entre unidades amostrais por meio de efeitos aleatórios (Wooldridge, 2020). Ambos tinham a taxa de ocupação trimestral como variável dependente.

A comparação entre modelos utilizou o erro absoluto médio [MAE] sob validação cruzada do tipo GroupKFold, uma variante do K-fold clássico na qual os subconjuntos respeitam agrupamentos predefinidos, no presente estudo, cada imóvel funcionou como um grupo, de modo que suas quatro observações trimestrais permaneceram sempre juntas, em treino ou em validação. A base foi repartida em quatro "splits", sendo cada split uma divisão

entre conjunto de treino e conjunto de validação. A cada rodada, três dos quatro subconjuntos formaram o treino e o restante serviu de validação, até que toda observação fosse avaliada uma vez; a métrica reportada corresponde à média das quatro rodadas. O número de partições foi definido em quatro para refletir a estrutura temporal da amostra, composta de quatro "snapshots" trimestrais. Esse desenho impediu que observações de um mesmo estúdio aparecessem simultaneamente em treino e validação, evitando vazamento de informação — prática recomendada quando os dados apresentam estrutura de grupos correlacionados (Hastie et al., 2009). Entre os modelos avaliados, o critério de seleção final privilegiou o equilíbrio entre desempenho preditivo e simplicidade interpretativa.

Como alternativa aos modelos lineares, foram testados de forma complementar os modelos Random Forest [RF] e Gradient Boosting [GB], duas alternativas não lineares da família de árvores de decisão. A diferença entre elas está no modo de combinar as árvores. O RF treina várias em paralelo, cada uma sobre uma amostra "bootstrap" da base e um subconjunto aleatório dos preditores, e agrega os resultados pela média. Já o GB encadeia árvores em sequência, cada nova treinada para corrigir os resíduos da anterior. Os dois capturam interações e não linearidades sem que o analista precise especificá-las, mas pagam um preço: em amostras modestas, a flexibilidade vira sobreajuste (Hastie et al., 2009). A validação cruzada agrupada seguiu o mesmo desenho aplicado aos modelos lineares.

Algoritmos "Multi-Armed Bandits"

Formalizou-se a estrutura de precificação dinâmica como um problema de "Multi-Armed Bandits" [MAB] (Auer et al., 2002). Cada "braço" correspondeu a uma faixa de preço da diária, e a recompensa associada a cada decisão foi a receita estimada, conforme a eq. (1):

$$Receita_t = preço_t \times occ_rate_estimada(preço_t, contexto_t),$$

em que: $Receita_t$ é a receita estimada na rodada t ; $preço_t$ é o preço selecionado pelo algoritmo; $occ_rate_estimada$ é a taxa de ocupação prevista pela função de demanda, condicionada ao preço e ao vetor de contexto do imóvel, $contexto_t$.

A cada rodada, o algoritmo selecionava um braço, observava a recompensa resultante acrescida de ruído estocástico gaussiano ($\sigma = 0,08$), simulando a incerteza inerente ao comportamento real da demanda (Qu, 2024), e atualizava sua política de seleção. Dez braços foram testados com preços de R\$ 100 a R\$ 1.000 em intervalos de R\$ 100, cobrindo o intervalo entre o percentil 25 e o percentil 90 da distribuição amostral. As simulações utilizaram 1.000 rodadas e 50 repetições estocásticas para cada cenário, com dez imóveis selecionados aleatoriamente como representantes do mercado.

O algoritmo ϵ -Greedy seleciona, com probabilidade $1 - \epsilon$, o braço com maior recompensa média estimada (exploração) e, com probabilidade ϵ , um braço aleatório (exploração). Adotou-se $\epsilon = 0,10$. A regra de decisão é formalizada na eq. (2):

$$a_t = \begin{cases} \arg \max_i \bar{Q}_i & \text{com probabilidade } 1 - \epsilon \\ \text{braço aleatório uniforme} & \text{com probabilidade } \epsilon \end{cases}$$

em que: a_t é a ação selecionada na rodada t ; $\bar{Q}_i$ é a recompensa média estimada do braço i ; ϵ é o parâmetro de exploração.

O algoritmo UCB seleciona o braço que maximiza um índice composto pela média das recompensas observadas acrescida de um bônus de exploração. O índice é definido pela eq. (3):

$$UCB_i(t) = \bar{Q}_i + c \sqrt{\frac{\ln t}{n_i}}$$

em que: $\bar{Q}_i$ é a recompensa média acumulada do braço i ; n_i é o número de seleções do braço i ; t é o número total de rodadas; c é o parâmetro de exploração ($c = 2,0$). Auer et al. (2002) demonstraram que o UCB atinge "regret" logarítmico em tempo finito, sendo assintoticamente ótimo para ambientes estacionários.

O "Thompson Sampling" [TS] adota abordagem bayesiana: para cada braço mantém-se uma distribuição *a posteriori* sobre a recompensa esperada. A cada rodada, amostra-se um valor de cada distribuição e seleciona-se o braço com o maior valor amostrado. A atualização bayesiana segue a eq. (4):

$$\mu_i \mid \tau \sim \mathcal{N}\left(\mu_n, \frac{1}{\lambda_n \tau}\right), \quad \tau \sim \text{Gamma}\left(\frac{\alpha_n}{2}, \frac{\beta_n}{2}\right)$$

em que: μ_n é a média do "posterior" para o braço i , atualizada a partir das recompensas observadas; λ_n é o fator de precisão do "prior" sobre a média, atualizado com o número de observações; α_n e β_n são parâmetros de forma e escala da distribuição Gamma sobre a precisão τ , atualizados após n_i observações do braço i .

A implementação utilizou distribuições Normal-Gamma, que permitem atualização conjugada eficiente. Russo et al. (2018) observaram que o TS apresenta "regret" esperado da ordem $O(d\sqrt{T} \log T)$ em "bandits" lineares e desempenho empírico superior em cenários não

estacionários. Jain et al. (2024), em estudo sobre problemas de escolha discreta com múltiplas promoções, verificaram que variantes adaptativas do TS produziram ganhos expressivos sobre políticas estáticas de precificação.

Os "notebooks" de análise e simulação encontram-se documentados junto ao repositório do [projeto](#).

Commented [LG5]: Apresentar o link do github ou semelhante

Resultados e Discussão

Análise descritiva da base

A base analítica compreendeu 571 imóveis classificados como estúdio ou apartamento compacto, distribuídos por 32 bairros do Rio de Janeiro. A Zona Sul concentrou a maior parte das observações: Copacabana respondeu por 43,2%, seguida por Ipanema com 11,2%, Leblon com 8,1% e Centro com 8,0%, conforme detalhado na Tabela 2. Em termos de tipologia, "rental unit" predominou com 82,0% da amostra, enquanto "loft" representou 10,2% e "condo" os 7,8% restantes. A capacidade distribuiu-se de forma bimodal: dois hóspedes concentraram 64,1% dos imóveis, ao passo que três hóspedes responderam por 35,6%.

Tabela 2. Distribuição geográfica da amostra, preços medianos e ocupação média por bairro

Bairro	Obs.	% da amostra	Preço mediano (R\$)	Ocupação média (dias)
Copacabana	986	43,2%	266,50	35,1
Ipanema	255	11,2%	368,00	37,7
Leblon	184	8,1%	542,00	34,6
Centro	182	8,0%	170,50	28,1
Jacarepaguá	100	4,4%	184,00	28,1
Barra da Tijuca	96	4,2%	390,00	30,2
Botafogo	80	3,5%	254,00	46,7
Flamengo	71	3,1%	215,00	45,7
Outros (24 bairros)	330	14,5%	—	—

Fonte: Resultados originais da pesquisa

A taxa de ocupação trimestral — variável-alvo do estudo — exibiu média de 34,6 dias equivalentes a 38,0% de ocupação, mediana de 31 dias e desvio padrão de 23,7 dias. Aproximadamente 4,2% das observações apresentaram ocupação nula. A sazonalidade manifestou-se de forma pronunciada.

No verão, a ocupação atingiu 43,1 dias em média, superando o inverno em 53% — período em que a média caiu para 28,2 dias, com o detalhamento de cada estação transcrito na Tabela 3. Esse padrão reflete o perfil turístico consolidado da cidade. Botafogo e Flamengo emergiram como os bairros mais demandados, com 46,7 e 45,7 dias de ocupação média respectivamente, apesar de praticarem preços medianos moderados; essa combinação sugere que os hóspedes percebem forte relação custo-benefício nessas localidades.

Tabela 3. Estatísticas descritivas da ocupação trimestral por estação

Estação	Período ref.	Média (dias)	Mediana (dias)	Desvio padrão
Verão	Dez/2024	43,1	44,0	22,7
Outono	Mar/2025	36,0	32,0	23,1
Primavera	Set/2024	31,2	28,0	24,3
Inverno	Jun/2024	28,2	24,0	22,1

Fonte: Resultados originais da pesquisa

A distribuição de preços revelou assimetria à direita, com média de R\$ 415,91 e mediana de R\$ 282,00. Os preços do verão foram, em média, 3,1 vezes superiores aos do inverno. Os indicadores de qualidade percebida — restritos a "superhosts" — mantiveram-se consistentemente elevados, com médias superiores a 96 pontos e baixa dispersão. O nota de avaliação de custo-benefício apresentou a maior variabilidade (desvio padrão = 2,54), sugerindo ser o indicador mais sensível às diferenças reais de desempenho entre imóveis.

Resultados do PCA e seleção de variáveis

Os testes de adequação amostral confirmaram a viabilidade da fatoração: o índice KMO atingiu 0,88, classificado como meritório, enquanto o teste de esfericidade de Bartlett rejeitou a hipótese nula ($\chi^2 = 2.117$; $p < 0,001$). A matriz de correlação de Pearson entre os seis notas de avaliações (Figura 2) ilustrou a redundância que motivou a redução dimensional — as correlações variaram de 0,38 (limpeza e "check-in") a 0,75 (nota geral e precisão), com um bloco particularmente coeso entre os indicadores de qualidade do imóvel.

Commented [LG6]: Eu sugeriria alterar o nome das variáveis para ficar mais "limpo". Tirar o review-scores por exemplo. So uma sugestao..




Figura 2. "Heatmap" de correlação de Pearson entre os as notas de avaliação utilizadas na Análise de Componentes Principais

Fonte: Resultados originais da pesquisa

O primeiro componente principal capturou 64,7% da variância total das 6 notas com cargas fatoriais equilibradas como ilustrado na Tabela 4. Nenhum indicador isolado dominou o componente, consolidando-o como referência consistente de qualidade percebida. Dois agrupamentos internos emergiram da matriz de correlação: um ligado à qualidade do imóvel, nota geral, precisão, limpeza e custo-benefício (correlações entre 0,60 e 0,75); e outro à qualidade do atendimento ("check-in" e comunicação, $\rho = 0,58$). Apesar dessas duas estruturas, selecionou-se apenas um componente por dois motivos: a captura de quase dois terços da variância já era expressiva, e um segundo componente adicionaria complexidade sem ganho interpretativo relevante. O componente foi invertido para que maiores valores representassem maior qualidade, denominado `quality_score`, e posteriormente incorporado à modelagem.

Tabela 4. Cargas fatoriais do primeiro componente principal (`quality_score`)

Tipos de Notas de Avaliação	"Loading" (PC1)	Agrupamento
Nota geral ("rating")	0,45	Qualidade do imóvel
Precisão ("accuracy")	0,44	Qualidade do imóvel
Limpeza ("cleanliness")	0,41	Qualidade do imóvel

Custo-benefício ("value")	0,41	Qualidade do imóvel
Comunicação ("communication")	0,38	Qualidade do anfitrião
"Check-in"	0,35	Qualidade do anfitrião

Fonte: Resultados originais da pesquisa

A correlação marginal entre preço e ocupação apresentou sinal positivo ($\rho = +0,12$) no nível agregado, resultado aparentemente contraintuitivo. Essa anomalia refletiu a presença de uma variável de confusão: imóveis de melhor qualidade e localização praticam preços mais elevados e recebem maior demanda simultaneamente. Ao desagregar por período, o sinal inverteu-se em três dos quatro "snapshots" ($\rho = -0,053$ em junho de 2024; $-0,012$ em setembro de 2024; $-0,123$ em março de 2025), revelando o padrão esperado pela teoria econômica. O controle por qualidade no modelo multivariado tornou-se, portanto, essencial para isolar o efeito do preço.

A seleção final eliminou variáveis redundantes. A variável `discount_vs_median` apresentava correlação de 0,88 com `log_price`; sua inclusão simultânea causou ausência de significância em ambas ($\beta \approx 0,000$ para `discount_vs_median`, $p = 0,956$). O `quality_score`, embora relevante para controlar a confusão preço-qualidade, não alcançou significância no modelo expandido com 11 preditores — provavelmente porque sua variação intragrupo foi inferior a 10%, assim como a maioria das demais variáveis. `Log_host_total_listings_count` e `accommodates` foram também eliminadas por não atingirem $p < 0,05$. O conjunto final de sete preditores foi encaminhado para a modelagem. O conjunto final de sete preditores, detalhado na Tabela 5, foi encaminhado para a modelagem.

Tabela 5. Variáveis selecionadas para o modelo final de demanda

Variável	Tipo	ρ Spearman	Papel
<code>log_price</code>	Contínua	+0,116	Alavanca do MAB — variável de decisão
<code>review_scores_location</code>	Contínua	+0,102	Localização percebida pelo hóspede
<code>log_number_of_reviews</code>	Contínua	+0,182	Popularidade e visibilidade
<code>bairro_mean_ocup</code>	Contínua	+0,083	"Proxy" de demanda local do bairro
<code>estacao_verao</code>	"Dummy"	—	Sazonalidade — verão vs. inverno (ref.)
<code>estacao_outono</code>	"Dummy"	—	Sazonalidade — outono vs. inverno (ref.)

estacao_primavera "Dummy" — Sazonalidade — primavera vs. inverno (ref.)

Fonte: Resultados originais da pesquisa

Modelo de demanda

O modelo OLS foi adotado como modelo final. Seu desempenho preditivo igualava o do modelo misto, ambos com erro absoluto médio de 18,6 dias, mas oferecia maior simplicidade interpretativa. O modelo misto indicou que a variância entre imóveis era pequena face ao erro residual, não compensando a complexidade adicional. O OLS estimado segue a eq. (5):

$$occ_rate = \beta_0 + \beta_1 \cdot a + \beta_2 \cdot b + \beta_3 \cdot c + \beta_4 \cdot d + \beta_5 \cdot e + \beta_6 \cdot f + \beta_7 \cdot g + \varepsilon$$

em que: *occ_rate* é a taxa de ocupação trimestral (dias ocupados / 91); *log_price* (*a*) é o logaritmo natural do preço da diária acrescido de uma unidade; *review_scores_location* (*b*) é a nota da valiação de localização percebida; *log_number_of_reviews* (*c*) é o logaritmo natural do número de avaliações; *bairro_mean_ocup* (*d*) é a ocupação média do bairro; *estacao_outono* (*e*), *estacao_primavera* (*f*) e *estacao_verao* (*g*) são variáveis indicadoras de sazonalidade, com inverno como categoria de referência; e ε é o termo de erro.

Todos os sete preditores alcançaram significância ao nível de 5% como visível na Tabela 6. O modelo apresentou $R^2 = 10,0\%$, consistente entre treino e validação cruzada agrupada por imóvel.

Tabela 6. Coeficientes do modelo OLS final de demanda (variável dependente: taxa de ocupação trimestral)

Variável	Coeficiente (β)	Erro padrão	p-valor	Interpretação
Intercepto	-0,189	0,068	0,006	Taxa base (inverno, <i>log_price</i> médio)
<i>log_price</i>	-0,046	0,013	<0,001	Preço sobe → ocupação cai
<i>review_scores_location</i>	+0,010	0,004	0,006	Melhor localização → mais demanda
<i>log_number_of_reviews</i>	+0,033	0,007	<0,001	Mais visibilidade → mais reservas

bairro_mean_ocup	+0,009	0,003	0,007	Bairro com mais demanda beneficia o imóvel
estacao_outono	+0,078	0,012	<0,001	+7,8 pp de ocupação vs. inverno
estacao_primavera	+0,030	0,011	0,009	+3,0 pp de ocupação vs. inverno
estacao_verao	+0,182	0,019	<0,001	+18,2 pp de ocupação vs. inverno

Fonte: Resultados originais da pesquisa

O coeficiente do logaritmo do preço ($\beta = -0,046$) representa uma semielasticidade: um aumento de 1% no preço da diária associa-se a uma redução de aproximadamente 0,046 pontos percentuais na taxa de ocupação trimestral. Uma observação importante: a correlação positiva de +0,30 entre variações de preço e variações de ocupação dentro do mesmo imóvel indica endogeneidade preço-ocupação. Essa relação tende a atenuar a estimativa obtida, sugerindo que o efeito causal do preço sobre a demanda é plausivelmente mais negativo do que o coeficiente indica. A comparação com modelos não lineares confirmou essa escolha.

O "Random Forest" atingiu R^2 "in-sample" de 33,2%, mas caiu para 7,9% em validação — evidência clara de "overfitting". O "Gradient Boosting" revelou inflação ainda maior "in-sample" (42,4%) com colapso na validação (4,5%). O erro absoluto médio em validação cruzada foi equivalente nos três modelos ($\approx 18,6$ dias). O OLS, com R^2 estável em torno de 10%, confirmou-se como modelo final. A Tabela 7 apresenta um resumo das principais informações sobre a comparação entre os modelos.

Tabela 7. Comparação de desempenho entre modelos de demanda (GroupKFold, 4 "splits")

Modelo	R^2 "in-sample"	R^2 "cross-val"	MAE "in-sample" (dias)	MAE CV (dias)	Diagnóstico
OLS (7 "features")	10,0%	$\sim 10,0\%$	18,6	18,6	Sem "overfitting"
"Random Forest"	33,2%	7,9% $\pm 2,7\%$	15,9	18,7	"Overfitting" severo
"Gradient Boosting"	42,4%	4,5% $\pm 3,0\%$	14,6	18,7	"Overfitting" severo

Fonte: Resultados originais da pesquisa

Um R^2 de 10% não representou fragilidade; traduziu o limite empírico observado com as variáveis disponíveis. A decomposição da variância revelou que 54,1% da variação ocorre entre imóveis e 61,2% intragrupo ao longo do tempo. A maioria das variáveis selecionadas apresentou variação intragrupo inferior a 10%, significando que o modelo tenta explicar flutuações temporais com preditores predominantemente fixos — limitação estrutural do conjunto de dados. A avaliação de variáveis não exploradas (contagem de amenidades, tipo de propriedade, quartos, banheiros, noites mínimas) não identificou candidatas com correlação superior a 0,11 com a variável-alvo. Valores de R^2 superiores reportados na literatura — 0,81 por Di Persio e Lalmi (2024) e 0,76 por Camatti et al. (2024) — foram alcançados com variáveis financeiras históricas e processamento de linguagem natural, informações não disponíveis em bases públicas.

O diagnóstico gráfico do modelo OLS (Figura 3) não revelou padrões sistemáticos nos resíduos. A dispersão contra valores preditos (primeiro gráfico) mostrou-se aleatória em torno de zero, embora com amplitude crescente nas faixas de maior ocupação predita — indicativo de heterocedasticidade moderada. Os resíduos distribuíram-se de forma aproximadamente simétrica, com média nula e desvio padrão de 0,247 (segundo gráfico); a leve assimetria positiva decorreu de observações cuja ocupação real superou o previsto pelo modelo. O painel de valores reais contra previstos (terceiro gráfico) confirmou que o modelo captura a tendência central da ocupação, mas comprime as predições na faixa intermediária sem alcançar os extremos, comportamento coerente com um R^2 de 10% e com a predominância de preditores de baixa variação temporal.




Figura 3. Diagnóstico de resíduos do modelo OLS de demanda: dispersão de resíduos (A), histograma dos resíduos (B) e valores reais vs. previstos (C)

Fonte: Resultados originais da pesquisa

O `quality_score` não foi retido no modelo OLS por falta de significância estatística, mas os modelos baseados em árvores o classificaram como preditor de maior importância individual (21,8% no "Gradient Boosting"; 17,2% no "Random Forest"). Essa aparente contradição explicou-se pela natureza distinta dos modelos. No OLS com dados em painel, a

quase constância do `quality_score` entre períodos limita sua capacidade de explicar variação temporal; nos modelos de árvore, as interações não lineares e diferenças entre imóveis tornam essa variável discriminante. O `quality_score` cumpriu assim seu papel conceitual: identificar e controlar a confusão entre qualidade e preço.

A curva de demanda estimada (Figura 4) manteve-se monotonicamente decrescente em todas as estações, confirmando a relação negativa esperada. A receita estimada, produto do preço vezes ocupação, cresceu monotonicamente no intervalo testado (R\$ 100 a R\$ 1.000), sem ponto de máximo interno. Essa característica decorreu da baixa semielasticidade ($\beta = -0,046$): o ganho unitário por diária superou sistematicamente a perda marginal de ocupação. Em faixas de preço muito acima das praticadas, onde a demanda provavelmente acelera sua queda, a curva de receita presumivelmente apresentaria ponto de máximo. Porém, como os anfitriões raramente testam preços extremos, o modelo não dispôs de observações nessas regiões.




Figura 4. Curva de demanda estimada: ocupação trimestral prevista em função do preço da diária, por estação

Fonte: Resultados originais da pesquisa

Simulação MAB — cenário estacionário

O cenário estacionário simulou 1.000 rodadas durante o verão em 50 repetições. O UCB obteve a maior receita acumulada média (R\$ 40,3 mil), seguido por ϵ -Greedy (R\$ 37,2 mil) e "Thompson Sampling" (R\$ 35,3 mil). Os principais indicadores comparativos entre os três modelos são encontrados na Tabela 8.

Tabela 8. Resultados da simulação MAB no cenário estacionário (verão, 1.000 rodadas, 50 repetições)

Algoritmo	Receita média (R\$ mil)	P10 (R\$ mil)	P90 (R\$ mil)	Braço preferido	Concentra ção
UCB	40,3	30,6	46,2	R\$ 1.000	94,4%
ϵ -Greedy ($\epsilon=0,1$)	37,2	28,4	43,5	R\$ 1.000	79,7%
"Thompson Sampling"	35,3	27,8	43,0	R\$ 1.000	51,7%

Fonte: Resultados originais da pesquisa

A evolução temporal da receita acumulada (Figura 5) evidenciou trajetórias distintas. O UCB separou-se dos demais já nas primeiras 100 rodadas, fase em que o ϵ -Greedy e o "Thompson Sampling" ainda acumulavam custo exploratório visível — o "zoom" das rodadas iniciais mostra as três curvas próximas até a rodada 40, com o UCB abrindo vantagem a partir daí. Após a rodada 200, as inclinações estabilizaram-se e a ordenação entre algoritmos não se alterou mais, indicando que as políticas de seleção já haviam convergido.




Figura 5. Receita acumulada por algoritmo no cenário estacionário (verão, 1.000 rodadas, 50 repetições)

Fonte: Resultados originais da pesquisa

Os três algoritmos convergiram para o braço de preço mais elevado (R\$ 1.000), o que era esperado dada a curva de demanda estimada — nesse intervalo, a receita cresce monotonicamente com o preço. Isso, porém, impõe uma limitação à análise: como não há ponto de inflexão na função de receita dentro da faixa testada, identificar o braço ótimo se torna um problema relativamente trivial. Em cenários onde a elasticidade variasse mais — e o preço ótimo não fosse simplesmente o mais alto —, as diferenças de desempenho entre ϵ -Greedy, UCB e Thompson Sampling provavelmente apareceriam com mais clareza. Ainda assim, o valor da abordagem MAB está menos na otimização em si e mais na exploração

empírica de faixas de preço que os anfitriões nunca testaram. Qu (2024) formalizou esse argumento ao apontar que a principal contribuição desses algoritmos é justamente revelar regiões desconhecidas da curva de demanda, sem depender de uma modelagem econométrica precisa.

A distribuição de braços selecionados (Figura 6) tornou esse contraste visível. O UCB, após testar cada braço uma vez, direcionou 94,4% das rodadas ao braço de R\$ 1.000, mantendo exploração mínima. O ϵ -Greedy dedicou sistematicamente 10% das rodadas à exploração aleatória, distribuída uniformemente entre todos os braços — a camada fina e homogênea no painel esquerdo é consequência mecânica do parâmetro $\epsilon = 0,10$. O "Thompson Sampling" manteve exploração ativa ao longo de todo o horizonte: 51,7% das seleções concentraram-se no braço preferido, 28,1% no braço de R\$ 800 e 12,1% no de R\$ 650, refletindo a incerteza residual da distribuição *a posteriori* mesmo após 1.000 rodadas (Russo et al., 2018). O painel direito, de receita por rodada em média móvel, confirmou que essa exploração mais ampla do TS custou entre R\$ 2 mil e R\$ 3 mil por rodada em estado estacionário frente ao UCB — o "preço" da informação sobre braços subótimos.

Commented [LG7]: Apresentar um pouco da interpretação desses resultados..




Figura 6. Distribuição de braços selecionados por algoritmo no cenário estacionário

Fonte: Resultados originais da pesquisa

Simulação MAB — cenário multi-estação

A simulação multi-estação replicou um ciclo sazonal completo: inverno, primavera, verão e outono, com mudança de contexto a cada 250 rodadas. Os resultados desta simulação se encontram na Tabela 9.

Tabela 9. Resultados da simulação MAB no cenário multi-estação (4 estações × 250 rodadas, 50 repetições)

Algoritmo	Receita média (R\$ mil)	P10 (R\$ mil)	P90 (R\$ mil)	Queda vs. cenário fixo
UCB	29,7	26,4	35,0	-26,4%
ϵ -Greedy ($\epsilon=0,1$)	27,8	24,6	33,2	-25,2%
"Thompson Sampling"	27,2	22,2	31,5	-23,1%

Fonte: Resultados originais da pesquisa

A diferença relativa entre os algoritmos reduziu-se em comparação ao cenário estacionário. A receita acumulada ao longo das quatro estações (Figura 7) revelou, porém, uma dinâmica que a tabela sozinha não capta: as curvas dos três algoritmos caminharam praticamente sobrepostas durante o inverno e a primavera, e a separação só se consolidou a partir do verão, quando a demanda mais alta ampliou a recompensa dos braços superiores. As faixas de incerteza — mais largas no TS e mais estreitas no UCB — refletiram o grau de exploração mantido por cada estratégia.




Figura 7. Receita acumulada por algoritmo no cenário multi-estação (4 estações × 250 rodadas, 50 repetições)

Fonte: Resultados originais da pesquisa

Os padrões de adaptação variaram por estação de modo revelador. O UCB convergiu rapidamente em todas elas: já no inverno, direcionou 79,2% das seleções ao braço de R\$ 1.000, mantendo-se em torno de 84% nas estações posteriores. Esse comportamento uniforme expõe uma limitação — o UCB não respondeu às mudanças de contexto sazonal, aderindo à política aprendida no primeiro período. O ϵ -Greedy apresentou convergência mais lenta no inverno (47,1%), estabilizando-se em torno de 82% a partir do outono.

O "Thompson Sampling" exibiu padrão radicalmente distinto, e o heatmap de braços por estação (Figura 8) tornou essa diferença inequívoca. A concentração no braço de R\$ 1.000 cresceu progressivamente: 30% no inverno, 52% na primavera, 63% no verão e 66% no outono. Durante o inverno, 70% das seleções distribuíram-se entre braços intermediários (R\$ 500 a R\$ 800), refletindo maior incerteza sobre qual faixa maximizaria a receita em período de demanda inferior. Esse gradiente de exploração para exploração ilustrou o aprendizado bayesiano contínuo: a cada nova observação, a distribuição *a posteriori* concentrou-se em torno do braço com maior recompensa sem abandonar completamente a exploração (Jain et al., 2024; Russo et al., 2018).




Figura 8. "Heatmap" da distribuição de braços selecionados pelo "Thompson Sampling" por estação

Fonte: Resultados originais da pesquisa

Síntese dos objetivos específicos e discussão integrada

O projeto de pesquisa original formulou cinco subperguntas que orientaram a análise. Os resultados obtidos são discutidos a seguir à luz de cada uma delas.

A qualidade percebida (quality_score) e a visibilidade (número de avaliações) emergiram como principais determinantes da demanda em nível de imóvel, conforme a análise de importância dos modelos baseados em árvores. O modelo OLS reafirmou essa hierarquia, situando a sazonalidade como fator dominante, seguida pela visibilidade e pela localização. O preço, variável de decisão dos algoritmos MAB, ocupou terceira posição (~15% nos modelos não lineares), sinalizando espaço para otimização, embora o ganho marginal esteja limitado pela semielasticidade observada.

A sazonalidade exerceu impacto expressivo. Ao transitar do cenário estacionário (verão) para o multi-estação, a receita declinou 23% a 26% para todos os algoritmos. O "Thompson Sampling" sofreu queda relativa menor (-23,1%), enquanto o UCB foi mais

Commented [LG8]: Ok. Você apresenta a "interpretação" dos resultados separado..

afetado (-26,4%). Esses números apontaram que a exploração contínua do TS, característica intrínseca da abordagem bayesiana, o torna mais robusto frente a mudanças de contexto.

O UCB conquistou a maior receita acumulada em ambos os cenários. Essa superioridade, todavia, comportou nuances. Em termos de receita absoluta, o UCB liderou. Em adaptabilidade, o "Thompson Sampling" revelou vantagem relativa. Tuncay et al. (2024) documentaram, em aplicação ao setor hoteleiro, que modelos de aprendizado por reforço superaram estratégias estáticas com dados reais, validando o potencial dessa abordagem em contextos similares.

A estabilidade do UCB — direcionando consistentemente mais de 79% das seleções ao braço preferido em todas as estações — decorreu de uma peculiaridade: não respondeu às mudanças de contexto, mantendo a mesma política aprendida no inverno. O "Thompson Sampling" demonstrou adaptação gradual, redistribuindo seleções entre braços a cada estação. A pesquisa não simulou choques exógenos de oferta, limitação reconhecida em relação ao escopo originalmente proposto.

Os "trade-offs" entre exploração e exploração diferenciaram os algoritmos de forma notável. O UCB concentrou 94,4% das seleções no braço preferido (cenário estacionário), minimizando exploração. O ϵ -Greedy dedicou 10% das rodadas a exploração aleatória indiscriminada. O "Thompson Sampling" dirigiu 48,3% das seleções para fora do braço preferido, distribuindo-as proporcionalmente à incerteza residual da distribuição *a posteriori*. O custo dessa exploração adicional foi de aproximadamente 14% da receita no cenário estacionário e de 9% no dinâmico. A redução dessa diferença com a mudança de contexto indicou que a exploração do TS adquire valor parcial quando o ambiente não permanece estável.

Os achados confirmaram as contribuições centrais do estudo. A função de demanda capturou a estrutura de mercado esperada: preço com efeito negativo significativo, sazonalidade como fator dominante, visibilidade como principal determinante de ocupação. Os algoritmos MAB demonstraram capacidade de convergência para faixas de preço superiores baseando-se exclusivamente em dados de recompensa observados, prescindindo de conhecimento prévio da curva.

A endogeneidade preço-ocupação identificada — correlação positiva de +0,30 entre variações de preço e ocupação dentro do mesmo imóvel — reforçou a justificativa MAB: ao explorar ativamente faixas de preço de forma quase experimental, o algoritmo isola o efeito causal de modo mais rigoroso do que estimadores observacionais puros. Foroughifar e Mehta (2024), contudo, alertaram para desafios de implementação: efetividade depende de acesso a dados em tempo real, capacidade de variação rápida de preços e disposição de absorver custos exploratórios. Neubert (2022) adicionou que a percepção de justiça pelos hóspedes

Commented [LG9]: Interessante retomar aqui as diferenças dessas duas abordagens

constitui fator limitante, sugerindo que a função de recompensa poderia incorporar penalidades para risco reputacional.

A recomendação do TS como estratégia preferencial, a despeito de o UCB ter alcançado receita absoluta superior em ambos os cenários, fundamentou-se em três argumentos convergentes. O mercado de aluguel por temporada é inerentemente não estacionário: sazonalidade, eventos locais, dinâmica competitiva e choques exógenos alteram continuamente a curva de demanda, e o TS, atualizando crenças bayesianas a cada observação, adapta-se sem exigir reinicialização ou ajuste manual. Os resultados indicaram que o custo exploratório do TS se reduziu de 14% para 9% na transição estacionária-dinâmica — tendência que sugere convergência ou inversão de vantagem em horizontes mais longos com mudanças frequentes. A vantagem convergente do UCB, por sua vez, pressupõe que o braço ótimo seja temporalmente estável; em ambientes reais, essa premissa é regularmente violada. Russo et al. (2018) formalizaram que o TS exhibe propriedades de adaptação superiores em cenários não estacionários, e Qu (2024) reafirmou que abordagens bayesianas tendem a superar métodos baseados em limites de confiança quando o horizonte é suficientemente longo e o ambiente sofre variações frequentes.

Conclusão

Os resultados demonstraram que algoritmos "Multi-Armed Bandits" adaptaram-se eficazmente a ambientes heterogêneos de precificação dinâmica. O modelo de demanda linear com sete preditores significativos revelou padrões consistentes, embora com elasticidade-preço limitada no intervalo observado. Essa característica explicou a convergência dos três algoritmos testados — ϵ -Greedy, UCB e "Thompson Sampling" — para os braços de preço superior, fenômeno que não desqualificou a abordagem, mas antes evidenciou um mercado com demanda inelástica e margens expressivas no segmento estudado.

O "Thompson Sampling" destacou-se como estratégia mais robusta. Em cenários estacionários, o UCB maximizou receita acumulada; no entanto, quando submetidos a dinâmicas sazonais típicas do aluguel de temporada, o TS apresentou queda relativa menor, sinalizando maior resiliência diante de mudanças abruptas. Esse desempenho refletiu a capacidade do algoritmo de atualizar distribuições posteriores de forma contínua, comportamento essencial em mercados sujeitos a variações competitivas e choques exógenos. O custo incremental de exploração adicional mostrou-se justificável como prêmio de adaptabilidade.

A análise carrega limitações que vale explicitar. A primeira delas é de natureza dos dados: por serem observacionais e públicos, os registros do Inside Airbnb não capturam bem

Commented [LG10]: Interessante!!

o comportamento de preço nas faixas extremas — anúncios muito baratos ou muito caros tendem a ter dinâmicas próprias que o dataset não revela. Soma-se a isso a endogeneidade entre preço e ocupação, que impede qualquer leitura causal dos coeficientes estimados na regressão. O recorte temporal também pesou: com apenas quatro períodos, a identificação de padrões sazonais mais profundos ficou comprometida. Do lado das simulações, a função de demanda adotada foi linear, o que simplifica um mercado que provavelmente opera com não linearidades relevantes. Por fim, o cenário de choque exógeno de oferta, originalmente previsto no projeto de pesquisa, acabou não sendo implementado, ficando como possibilidade para trabalhos futuros.

Pesquisas futuras poderão avançar em três direções. A incorporação de dados contextuais em tempo real, como preços concorrentes, eventos, variáveis climáticas, e viabilizaria "bandits" contextuais e decisões mais informadas. Algoritmos com mecanismos de desconto exponencial ou janelas deslizantes merecem também investigação, pois abordam mudanças rápidas de regime sem abandonar princípios de exploração-exploração. Por fim, a validação empírica por meio de experimento controlado com anfitriões reais permitiria aferir se os ganhos simulados persistem em dinâmica real no mercado de aluguel por temporada.

Referências

Abrate, G.; Sainaghi, R.; Mauri, A.G. 2022. Dynamic pricing in Airbnb: individual versus professional hosts. *Journal of Business Research* 141: 191-199.

Auer, P.; Cesa-Bianchi, N.; Fischer, P. 2002. Finite-time analysis of the multi-armed bandit problem. *Machine Learning* 47(2-3): 235-256.

Camatti, N.; Di Tollo, G.; Filograsso, G.; Ghilardi, S. 2024. Predicting Airbnb pricing: a comparative analysis of artificial intelligence and traditional approaches. *Computational Management Science* 21: 1-25.

Di Persio, L.; Lalmi, E. 2024. Maximizing profitability and occupancy: an optimal pricing strategy for Airbnb hosts using regression techniques and natural language processing. *Journal of Risk and Financial Management* 17(9): 414.

Foroughifar, M.; Mehta, N. 2024. The challenges of deploying an algorithmic pricing tool: evidence from Airbnb. Working Paper, Rotman School of Management, University of Toronto, Toronto, Canada.

Hastie, T.; Tibshirani, R.; Friedman, J. 2009. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. 2ed. Springer, New York, NY, USA.

Hollander, M.; Wolfe, D.A.; Chicken, E. 2013. *Nonparametric Statistical Methods*. 3ed. John Wiley & Sons, Hoboken, NJ, USA.

Inside Airbnb [Inside Airbnb]. 2024. Get the data. Disponível em: <http://insideairbnb.com/get-the-data.html>. Acesso em: 15 jun. 2025.

Commented [LG11]: Rever a formatação e o espaçamento

Jain, L.; Li, Z.; Loghmani, E.; Mason, B.; Yoganarasimhan, H. 2024. Effective adaptive exploration of prices and promotions in choice-based demand models. *Marketing Science* 43(5): 1002-1030.

Jolliffe, I.T.; Cadima, J. 2016. Principal component analysis: a review and recent developments. *Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences* 374(2065): 20150202.

Neubert, M. 2022. A systematic literature review of dynamic pricing strategies. *International Business Research* 15(4): 1-17.

Qu, J. 2024. Survey of dynamic pricing based on multi-armed bandit algorithms. *Applied and Computational Engineering* 37: 160-165.

Russo, D.; Van Roy, B.; Kazerouni, A.; Osband, I.; Wen, Z. 2018. A tutorial on Thompson sampling. *Foundations and Trends in Machine Learning* 11(1): 1-96.

Talón-Ballester, P.; González-Serrano, L.; Soguero-Ruiz, C.; Muñoz-Romero, S.; Rojo-Álvarez, J.L. 2022. The wheel of dynamic pricing: towards open pricing and one-to-one pricing in hotel revenue management. *International Journal of Hospitality Management* 102: 103184.

Tuncay, G.; Kaya, K.; Yılmaz, Y.; Yaslan, Y.; Gündüz Öğüdücü, Ş. 2024. A reinforcement learning based dynamic room pricing model for hotel industry. *INFOR: Information Systems and Operational Research* 62(2): 211-231.

Wilcox, R.R. 2021. *Introduction to Robust Estimation and Hypothesis Testing*. 5ed. Elsevier, Amsterdam, Netherlands.

Wooldridge, J.M. 2020. *Introductory Econometrics: a Modern Approach*. 7ed. Cengage Learning, Boston, MA, USA.

Ye, P.; Qian, J.; Chen, J.; Wu, C.; Zhou, Y.; De Mars, S.; Yang, F.; Zhang, L. 2018. Customized regression model for Airbnb dynamic pricing. p. 932-940. In: *Proceedings of the 24th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*. ACM, London, UK.